

PROYECTO FINAL
DATA ANALYSIS+PYTHON 2026

REALIZADO POR DANIELA ESPINOZA

Este proyecto busca recomendar a una editorial para lograr optimizar su presupuesto de marketing mediante el **análisis de datos** de catálogos literarios (Goodreads).

Para evitar decisiones basadas únicamente en la popularidad superficial, el análisis distingue entre la **Calidad percibida** (calificación promedio) y el **Alcance comercial** (volumen de reseñas), identificando títulos con alto potencial de crecimiento.

¿QUÈ ES GOODREADS?

SEGÙN SU PÀGINA

“Goodreads es el sitio web más grande del mundo para lectores y recomendaciones de libros. Nuestra misión es ayudar a los lectores a descubrir libros que les apasionen y a disfrutar más de la lectura.

Goodreads se lanzó en enero de 2007.”

goodreads.com/about/us

DATASET A UTILIZAR

El dataset utilizado se obtuvo de Kaggle. Contiene 11127 registros de libros que fueron publicados entre el año 1900 y 2020.

Las columnas de este dataset son:
book_id, title, author, average_rating, isbn, isbn13, lang, num_pages, ratings_count, text_review_count, publication_date, publisher, genres


NUESTRA PREGUNTA PRINCIPAL DE NEGOCIOS



¿Qué características permiten identificar libros con alto potencial de éxito y cuáles deberían ser priorizados por una editorial para invertir en marketing?



Matriz Estratégica de Perfiles de Catálogo (Goodreads)



CARACTERÍSTICAS PROMEDIO DE CADA CUADRANTE							
	perfil_libro	total_libros	promedio_paginas	mediana_paginas	promedio_rating	mediana_evaluaciones	compromiso_escrito_promedio_pct
1. Éxitos Consolidados		1161	400.402239	352.0	4.154798	30401.0	3.487116
2. Consumo Masivo		935	358.009626	340.0	3.775444	23527.0	4.540073
3. Nicho / Alto Potencial		3049	379.331256	320.0	4.163549	932.0	6.863903
4. Bajo Desempeño		3239	305.756715	288.0	3.737339	898.0	8.180152

LAS HIPÓTESIS

H1 – EXTENSIÓN DEL LIBRO

Los libros de extensión media a larga (300 a 500 páginas) tienen una probabilidad significativamente mayor de pertenecer al perfil de Alto Potencial o Éxitos Consolidados que los libros de menos de 300 páginas.


H2 – REPUTACIÓN DEL AUTOR

La presencia de un autor con un catálogo previo bien valorado reduce el tiempo/riesgo de conversión de un libro de Alto Potencial hacia un Éxito Consolidado al recibir pauta publicitaria.

H3 – RATIO DE COMPROMISO (ENGAGEMENT RATIO)

El ratio de reseñas escritas sobre evaluaciones totales ($\text{text_reviews_count} / \text{ratings_count}$) es un predictor más sólido del perfil de Alto Potencial que la calificación promedio (average_rating) aislada.





Los libros demasiado cortos suelen percibirse como de “menor valor” o contenido incompleto, logrando menos tracción comercial masiva.

Los libros más extensos (350+ páginas) suelen pertenecer a géneros de gran lealtad (como Fantasía, Ciencia Ficción o Ficción Histórica), donde los lectores generan un compromiso mayor, dejan más calificaciones y puntúan con notas elevadas.

- Tasa de éxito
- Es popular: Su calificación promedio (average_rating) está por encima (o igual) a la mediana de todos los libros.
 - Es muy leído: Su cantidad de evaluaciones (ratings_count) está por encima (o igual) a la mediana de votos de todos los libros.

REPUTACIÓN DEL AUTOR

NIVEL DE ÉXITO	TOTAL_LIBROS	MEDIA_RATING_PREVIO_AUTOR	MEDIANA_POPULARIDAD_PREVIA_AUTOR
BAJO/MEDIO	3291	3,89	2807,0
ALTO	1311	4,05	5757,5


Los libros exitosos pertenecen a autores con antecedentes de calificaciones significativamente más altas en sus otras obras.

EL "ENGAGEMENT RATIO"

PERFIL DEL LIBRO	CANTIDAD DE LIBROS	% RESEÑAS ESCRITAS (MEDIANA)	CALIFICACIÓN PROMEDIO
BAJO/MEDIO ÉXITO	6202	6,66%	3,88 ★
ALTO ÉXITO	2200	3,54%	4,16 ★

No existe evidencia de que la tasa de reseñas escritas difiera entre libros exitosos y no exitosos.

Cuando miramos el porcentaje de compromiso escrito (es decir, cuántos usuarios dejan un texto en lugar de solo estrellas) notamos que en los libros exitosos la mediana es del 3.5%, mientras que en los menos exitosos es casi el doble (6.6%).



LAS RECOMENDACIONES FINALES

Para priorizar inversiones de marketing, el filtro mínimo de calidad debe fijarse en 4.1 o más estrellas.

Al evaluar manuscritos para campañas de gran alcance, priorizar libros con desarrollo de contenido robusto (300+ páginas), ya que generan mayor compromiso y valor percibido por parte del lector.

La reputación y la base de lectores establecida del autor son predictores sólidos del éxito comercial.

Asignar la mayor proporción del presupuesto de marketing a los top géneros del mercado, asegura una demanda base sólida y menor riesgo comercial.

Al cruzar calificación y cantidad de evaluaciones, surgen cuatro cuadrantes claros.

Destaca un grupo de libros con calificaciones excelentes (4.2+) pero bajo volumen de evaluaciones (< 20.000).


Estas "joyas ocultas" representan la oportunidad de mayor retorno de inversión (ROI) para la editorial, ya que cuentan con validación de calidad y solo requieren presupuesto de difusión para escalar en ventas.



SUPUESTOS Y LIMITACIONES

Integrar Procesamiento de Lenguaje Natural (NLP) para incorporar un análisis de sentimiento e identificación de temas clave sobre el texto de las reseñas escritas para comprender los factores cualitativos (trama, ritmo, desarrollo de personajes) que impulsan una calificación alta.





**AGRADECIMIENTO
ESPECIAL A
COMUNIDAD IT**

